

Sistema de Inferência de Mobilidade Urbana a partir de Dados de Sensores de Tráfego

Autor: João Pedro Pereira Martins

Data: Abril/Maio de 2026

Versão da Documentação: 1.0

**Tecnologias Principais: DuckDB,
Python (Pandas, Scikit-learn, Plotly, Streamlit)**

Introdução:

A crescente urbanização impõe desafios significativos à gestão da mobilidade nas cidades. Compreender os padrões de deslocamento dos veículos é fundamental para o planeamento de infraestruturas, otimização do transporte público e desenvolvimento de cidades mais inteligentes. No entanto, os dados brutos provenientes de sensores de tráfego são frequentemente volumosos, heterogêneos e não estruturados, o que dificulta a extração de conhecimento diretamente a partir deles.

O presente projeto documenta o desenvolvimento de um pipeline de dados completo e estruturado, concebido para transformar registos brutos de passagens veiculares em inferências de mobilidade acionáveis. Partindo de um conjunto de dados com aproximadamente 12 GB (cerca de 21 milhões de registos), o trabalho percorreu todas as etapas essenciais da análise de dados: desde a limpeza e padronização inicial, passando pela estruturação temporal dos percursos dos veículos, até à criação de zonas urbanas através de clusterização espacial e à construção de matrizes probabilísticas de origem-destino.

O principal objetivo deste projeto é demonstrar como é possível, através de uma abordagem metódica e com recurso a técnicas de inteligência artificial não supervisionada (como cadeias de Markov e clusterização KMeans), modelar a probabilidade de deslocamentos entre diferentes regiões de uma cidade. O resultado final é materializado num dashboard interativo que permite explorar os principais fluxos de tráfego, a robustez dos resultados e a aplicabilidade prática do modelo para apoiar decisões de planeamento urbano.

Resumo

Este projeto apresenta o desenvolvimento e a implementação de um pipeline analítico completo para inferir padrões de mobilidade urbana a partir de dados de sensores de tráfego. O trabalho abrange desde o pré-processamento de dados brutos até à construção de um dashboard interativo, passando pela modelagem probabilística dos deslocamentos entre zonas da cidade.

Metodologia:

O pipeline foi estruturado em nove fases principais. Inicialmente, os dados foram limpos, tipados e padronizados, convertendo 12 GB de arquivos CSV para o formato Parquet e tratando valores nulos e duplicados. Na segunda fase, os registos foram reorganizados por veículo para criar uma base de transições temporais. Seguiu-se uma clusterização espacial dos 26 sensores em 5 zonas urbanas utilizando o algoritmo KMeans, otimizado com métricas de silhueta e inércia.

Posteriormente, definiram-se sessões de viagem (por veículo, data e período do dia) para extrair pares origem-destino. Sobre estes, aplicou-se modelagem probabilística, incluindo uma matriz de transição de Markov para capturar a sequencialidade dos movimentos. Por fim, realizou-se uma avaliação de robustez metodológica e os resultados foram consolidados num dashboard interativo em Streamlit.

Principais Resultados:

A base final de eventos limpos continha 21.061.609 registos, referentes a 1.440.237 placas únicas e 26 sensores, cobrindo um período de 113 dias. A análise de robustez revelou que o principal fator que influencia a estrutura da matriz origem-destino é a presença de sessões com um único evento. O cenário metodológico recomendado (sessões com 2 ou mais eventos) aumentou o percentual de fluxos inter-zona de 11,98% para 48,62%. Foram identificados corredores de mobilidade consistentes e robustos entre diferentes cenários, destacando-se o fluxo *Zona 3 → Zona 1* como o padrão inter-zona mais frequente em todos os períodos do dia, com 246.108 deslocamentos no período da tarde.

Fase 1 — Limpeza, Tipagem e Padronização dos Dados

Objetivo

A primeira etapa do projeto teve como objetivo transformar os dados brutos de tráfego em uma base analítica limpa, consistente e pronta para as etapas posteriores de reconstrução de trajetórias parciais e inferência origem-destino.

Como os dados originais possuíam grande volume — aproximadamente 12 GB em arquivos CSV — foi realizada previamente a conversão para o formato Parquet, que oferece melhor desempenho de leitura e processamento para bases extensas. A partir dessa estrutura, foi executado um processo de limpeza, tipagem e padronização utilizando DuckDB, permitindo trabalhar com milhões de registros sem necessidade de carregar todo o conteúdo em memória.

Descrição da etapa

Nesta fase, os dados foram lidos a partir dos arquivos .parquet gerados anteriormente e organizados em uma base única e padronizada. O processo incluiu:

- padronização dos nomes das colunas;
- conversão dos tipos de dados;
- tratamento de datas e horários;
- conversão de colunas numéricas;
- remoção de registros com nulos em campos críticos;
- eliminação de duplicatas exatas;
- criação de variáveis temporais auxiliares para análise.

O objetivo foi garantir que cada leitura de sensor estivesse associada corretamente a um veículo, a um instante temporal válido e a uma posição geográfica consistente.

Colunas consideradas na base

A estrutura original dos dados continha as seguintes colunas relevantes para o projeto:

- **NSerie:** identificador do sensor viário;
- **Endereco:** endereço textual do ponto de captura;

- **Sentido:** direção da via no ponto monitorado;
- **Datatrafego:** data e hora da passagem do veículo;
- **Latitude e Longitude:** coordenadas geográficas do sensor;
- **Placa:** identificação anonimizada do veículo;
- **Velocidade 1:** velocidade registrada no momento da leitura;
- **Velocidade Regul:** velocidade regulamentada da via.

Após a padronização, essas colunas passaram a ser organizadas em nomes mais adequados para análise, como `sensor_id`, `timestamp`, `latitude`, `longitude`, `velocidade` e `velocidade_regulada`.

Tratamentos realizados

1. Conversão de tipos

As colunas originalmente identificadas como texto (object) foram convertidas para tipos apropriados:

- Datatrafego → timestamp
- Latitude → double
- Longitude → double
- Velocidade 1 → double
- Velocidade Regul → double

A conversão do campo de data foi realizada considerando o formato brasileiro dd/mm/aaaa hh:mm:ss.

2. Remoção de nulos críticos

Foram removidos registros com ausência de informação em campos essenciais para o projeto, especificamente:

- placa do veículo;
- identificador do sensor;
- timestamp;
- latitude;
- longitude.

Esses campos são indispensáveis para reconstrução da ordem temporal e da posição espacial das leituras.

3. Remoção de duplicatas exatas

Foi aplicado um filtro para eliminar registros exatamente duplicados, evitando contagem repetida de eventos idênticos.

4. Criação de variáveis derivadas de tempo

Também foram criadas novas variáveis auxiliares, importantes para análises temporais e segmentação posterior dos deslocamentos:

- data
- hora
- mes
- dia_semana_nome
- dia_semana_num
- fim_de_semana
- periodo_dia
- periodo_rush

Essas variáveis serão utilizadas nas próximas fases para analisar padrões por horário, dias úteis, fins de semana e períodos de pico.

Resultado da etapa

Ao final da Fase 1, foi gerado um arquivo consolidado e limpo:

eventos_limpos.parquet

Essa base passou a representar o conjunto principal de eventos de tráfego prontos para análise.

Resumo da base resultante

- **Total de linhas:** 21.061.609
- **Total de placas únicas:** 1.440.237
- **Total de sensores únicos:** 26
- **Período coberto:** de 2026-01-01 00:00:01 até 2026-04-23 23:59:55
- **Total de dias distintos:** 113

Validação da qualidade dos dados

Após a geração da base limpa, foi realizada uma etapa de validação para verificar a consistência da transformação.

Principais resultados da validação

1. Schema final

A base final apresentou os tipos esperados para análise:

- timestamp como TIMESTAMP
- latitude e longitude como DOUBLE
- velocidade e velocidade_regulada como DOUBLE

2. Nulos nas colunas críticas

A validação mostrou que não restaram valores nulos nos campos essenciais:

- sensor_id_nulo = 0
- placa_nula = 0
- timestamp_nulo = 0
- latitude_nula = 0
- longitude_nula = 0

3. Duplicatas exatas

Não foram encontradas duplicatas exatas remanescentes na base final.

4. Distribuição temporal

A distribuição das leituras por período do dia foi a seguinte:

- **Tarde:** 7.990.566 registros (37,94%)
- **Manhã:** 6.817.479 registros (32,37%)
- **Noite:** 5.226.213 registros (24,81%)
- **Madrugada:** 1.027.351 registros (4,88%)

Isso indica maior concentração de leituras nos períodos de maior atividade urbana, o que é coerente com o fenômeno estudado.

5. Dias úteis e fins de semana

- **Dias úteis:** 16.174.264 registros

- **Fim de semana:** 4.887.345 registros

Essa diferença também é esperada e reforça a coerência da base com padrões urbanos reais.

6. Distribuição por sensor

Os 26 sensores apresentaram volumes distintos de captura, o que já sugere diferenças de importância viária e cobertura espacial entre os pontos monitorados. Essa informação será importante nas fases de clusterização e interpretação dos fluxos.

7. Faixa de velocidade

Foi observada velocidade máxima de **999 km/h**, valor claramente inconsistente para o contexto urbano. Esse resultado sugere a presença de outliers ou códigos sentinela no campo de velocidade. Como a variável velocidade não é essencial para a definição inicial de origem-destino, essa inconsistência não inviabiliza a continuidade do projeto, mas será registrada como limitação e poderá ser tratada em análises complementares.

Conclusão da fase

A Fase 1 cumpriu com sucesso o objetivo de preparar os dados para as próximas etapas do projeto. A base resultante está limpa, tipada, sem nulos críticos e sem duplicatas exatas, além de conter variáveis temporais derivadas que facilitarão a análise de padrões de mobilidade.

Essa etapa é fundamental porque garante que as inferências posteriores sobre deslocamentos urbanos sejam construídas sobre uma estrutura de dados consistente e confiável.

Limitações identificadas nesta fase

Mesmo com a base limpa, algumas limitações já podem ser observadas:

- a velocidade contém valores anômalos em alguns registros;
- os sensores representam apenas pontos discretos da cidade, e não cobertura contínua do território;
- o endereço textual contém pequenos problemas de codificação de caracteres, como ocorrência de n? em vez de caracteres acentuados.

Essas limitações não impedem o avanço do projeto, mas devem ser registradas para interpretação adequada dos resultados.

Entrega da Fase 1

A entrega desta fase consiste em:

- base consolidada e limpa em formato Parquet;
- validação da consistência estrutural da base;
- documentação do processo de limpeza e padronização;
- preparação dos dados para a fase seguinte de estruturação por veículo.

Fase 2 — Estruturação dos Dados por Veículo

Objetivo

A Fase 2 teve como objetivo reorganizar os registros de tráfego na dimensão temporal de cada veículo, criando uma estrutura sequencial que permitisse identificar eventos consecutivos observados pelos sensores viários.

Como os dados disponíveis representam apenas passagens pontuais dos veículos em locais monitorados, e não trajetórias contínuas, foi necessário transformar essas leituras isoladas em uma base relacional de transições. Essa estrutura é fundamental para as próximas etapas do projeto, especialmente para a identificação de deslocamentos parciais, criação de sessões de viagem e posterior inferência de origem-destino.

Descrição da etapa

Nesta fase, foi utilizada como entrada a base limpa gerada na Fase 1 (eventos_limpos.parquet). A partir dessa base, os registros foram organizados por placa anonimizada e ordenados cronologicamente.

Para cada evento de um veículo, foi identificado o próximo evento correspondente à mesma placa, permitindo formar pares sequenciais do tipo:

evento atual → próximo evento

A cada par de eventos consecutivos foram associadas informações espaciais, temporais e contextuais, além do cálculo do intervalo entre as duas leituras.

Essa abordagem permitiu construir uma base de transições por veículo, em que cada linha representa uma passagem observada e sua conexão com a próxima leitura disponível do mesmo veículo.

Procedimento adotado

A estruturação foi realizada com base em duas variáveis centrais:

- **placa:** identificador anonimizado do veículo;
- **timestamp:** instante temporal da passagem registrada pelo sensor.

A lógica aplicada foi:

1. agrupar os registros por veículo;
2. ordenar cronologicamente os eventos de cada placa;

3. identificar o próximo evento de cada veículo;
4. calcular o intervalo de tempo entre o evento atual e o próximo;
5. registrar se o próximo evento ocorreu:
 - no mesmo sensor;
 - em sensor diferente;
 - na mesma data;
 - em data diferente.

Esse processo foi implementado com funções de janela em DuckDB, permitindo executar a etapa de forma eficiente sobre mais de 21 milhões de registros.

Variáveis geradas

A base resultante foi estruturada com informações do evento atual, do evento seguinte e das variáveis derivadas da transição.

Informações do evento atual

- placa
- sensor_atual
- endereco_atual
- sentido_atual
- timestamp_atual
- data_atual
- hora_atual
- mes_atual
- dia_semana_nome
- dia_semana_num
- fim_de_semana
- periodo_dia_atual
- periodo_rush_atual
- latitude_atual
- longitude_atual

- velocidade_atual
- velocidade_regulada_atual

Informações do próximo evento

- sensor_proximo
- endereco_proximo
- sentido_proximo
- timestamp_proximo
- data_proxima
- hora_proxima
- periodo_dia_proximo
- periodo_rush_proximo
- latitude_proxima
- longitude_proxima
- velocidade_proxima

Variáveis derivadas da transição

- delta_segundos
- delta_minutos
- mesmo_sensor
- mesma_data
- faixa_delta_tempo

Resultado da etapa

Ao final da Fase 2, foi gerado o arquivo:

transicoes_veiculos.parquet

Essa base passou a representar a estrutura temporal dos eventos por veículo e será utilizada nas etapas seguintes do projeto.

Resumo geral da base de transições

- **Total de transições registradas:** 21.061.609

- **Total de placas únicas:** 1.440.237
- **Eventos sem próximo evento:** 1.440.237
- **Eventos com próximo evento:** 19.621.372
- **Transições no mesmo sensor:** 5.008.438
- **Transições entre sensores diferentes:** 14.612.934

O número de eventos sem próximo evento é esperado, pois corresponde ao último registro de cada placa na base observada.

Validação da Fase 2

1. Estrutura da base

A validação mostrou que a base foi gerada corretamente, com colunas correspondentes ao evento atual, ao evento seguinte e às métricas de transição. Os tipos de dados também permaneceram consistentes, com datas em formato TIMESTAMP e coordenadas em DOUBLE.

2. Nulos esperados

Não foram encontrados nulos nas colunas do evento atual. Os nulos observados nas colunas do próximo evento (`sensor_proximo`, `timestamp_proximo`, `delta_minutos`) correspondem exclusivamente aos casos em que a leitura é a última observação daquela placa no período analisado.

Total de registros sem próximo evento:

- **1.440.237**

Esse valor coincide com o número total de placas únicas, confirmando consistência lógica da estrutura.

3. Mesmo sensor vs troca de sensor

Considerando apenas registros com próximo evento:

- **74,47%** das transições ocorreram entre sensores diferentes;
- **25,53%** ocorreram no mesmo sensor.

Esse resultado é relevante porque mostra que a maior parte das sequências observadas indica deslocamento entre pontos distintos da rede de sensores, o que reforça o potencial analítico da base para inferência de mobilidade.

4. Mesma data vs data diferente

Também considerando apenas registros com próximo evento:

- **42,96%** das transições ocorreram na mesma data;
- **57,04%** ocorreram em datas diferentes.

Esse resultado mostra que muitos encadeamentos consecutivos de uma mesma placa ultrapassam o limite de um único dia, o que indica a necessidade de regras adicionais de segmentação temporal nas próximas fases.

5. Distribuição do intervalo entre leituras

A distribuição da variável `faixa_delta_tempo` revelou forte concentração em intervalos longos:

- **mais_180min:** 13.894.527 registros (65,97%)
- **até_5min:** 1.780.804 registros (8,46%)
- **61a180min:** 1.719.316 registros (8,16%)
- **6a15min:** 934.348 registros (4,44%)
- **31a60min:** 724.866 registros (3,44%)
- **16a30min:** 567.511 registros (2,69%)

Esses resultados mostram que a sequência consecutiva de leituras de uma placa não representa necessariamente uma única viagem contínua, e sim o próximo evento observado no período total da base.

6. Estatísticas de `delta_minutos`

As estatísticas descritivas reforçam essa interpretação:

- **mínimo:** 0,0 minutos
- **máximo:** 161.411,22 minutos
- **média:** 3.684,12 minutos
- **mediana:** 1.016,47 minutos

Percentis:

- **p25:** 111,32 minutos
- **p75:** 2.888,17 minutos
- **p90:** 8.634,53 minutos
- **p95:** 15.858,22 minutos

- **p99:** 49.046,19 minutos

Esses valores indicam que há muitos intervalos extensos entre leituras consecutivas do mesmo veículo. Portanto, a base de transições deve ser interpretada como uma estrutura temporal bruta, ainda não segmentada em sessões de deslocamento.

7. Veículos com uma leitura vs múltiplas leituras

A contagem por veículo mostrou:

- **54,97%** dos veículos possuem 2 ou mais leituras;
- **45,03%** possuem apenas 1 leitura.

Isso significa que mais da metade dos veículos observados contribui para a análise sequencial, embora uma parcela relevante da frota não permita reconstrução de trajetória parcial.

8. Principais trocas entre sensores

Entre as transições mais frequentes entre sensores diferentes, destacam-se pares como:

- 1019 → 1755
- 1021 → 1022
- 1806 → 1078
- 1022 → 1021
- 1078 → 1081
- 1017 → 1134

Esses pares sugerem conexões recorrentes entre pontos monitorados e já indicam possíveis corredores ou continuidades espaciais relevantes para análise futura.

Interpretação dos resultados

A Fase 2 foi bem-sucedida ao estruturar os dados por veículo e criar uma base sequencial robusta para análise de deslocamentos. No entanto, a própria validação revelou um aspecto metodológico central do projeto:

o próximo evento de uma placa nem sempre representa continuidade direta de uma mesma viagem.

Isso acontece porque os sensores têm cobertura limitada e porque o intervalo entre duas leituras consecutivas pode ser muito grande. Dessa forma, a base de transições criada nesta etapa deve ser entendida como uma estrutura de encadeamento temporal bruto, que ainda precisará ser refinada por regras adicionais nas próximas fases.

Essa constatação é importante porque orienta corretamente o projeto: antes de inferir origem-destino, será necessário criar zonas espaciais e aplicar segmentação temporal adequada.

Limitações observadas na fase

As principais limitações identificadas nesta etapa foram:

- grande quantidade de transições com intervalo de tempo muito elevado;
- presença de eventos consecutivos em dias diferentes;
- parte expressiva dos veículos com apenas uma leitura;
- repetição de leituras no mesmo sensor, que pode representar ruído, permanência ou múltiplas passagens locais.

Essas limitações não invalidam a base, mas indicam a necessidade de filtros e segmentações posteriores para tornar a inferência de deslocamentos mais realista.

Conclusão da fase

A Fase 2 cumpriu com sucesso seu objetivo de transformar a base de eventos individuais em uma base de transições organizadas por veículo e tempo.

O principal produto da etapa foi uma estrutura temporal robusta, que já permite observar padrões de continuidade entre sensores. Além disso, a fase revelou informações essenciais para a continuidade do projeto, especialmente a necessidade de controlar o problema dos grandes intervalos entre leituras.

Com isso, a base está pronta para a próxima etapa, em que os sensores serão agrupados em zonas urbanas por meio de clusterização espacial.

Entrega da Fase 2

A entrega desta fase consiste em:

- base transicoes_veiculos.parquet;
- estruturação cronológica dos eventos por veículo;
- identificação do próximo evento por placa;
- cálculo do intervalo de tempo entre leituras;
- validação da consistência das transições;
- identificação de limitações temporais para as fases seguintes.

Fase 3 — Clusterização dos Sensores e Criação de Zonas

Objetivo

A Fase 3 teve como objetivo agrupar os sensores viários em zonas espaciais da cidade, reduzindo a complexidade da análise e tornando os resultados mais interpretáveis do ponto de vista urbano.

Em vez de trabalhar diretamente com deslocamentos entre sensores individuais, esta etapa transforma o problema em fluxos entre zonas, o que facilita a construção de matrizes origem-destino e a identificação de padrões regionais de mobilidade.

Essa decisão é importante porque os sensores representam pontos específicos e discretos da cidade, enquanto a análise de deslocamento urbano tende a fazer mais sentido quando agregada em regiões ou áreas funcionais.

Descrição da etapa

Nesta fase, foi utilizada como entrada a base de eventos limpos gerada na Fase 1. A partir dela, foi extraída uma tabela com os sensores únicos, contendo:

- identificador do sensor;
- endereço;
- latitude;
- longitude.

Como o conjunto contava com apenas **26 sensores distintos**, foi possível aplicar uma clusterização espacial simples e interpretável utilizando apenas as coordenadas geográficas dos pontos.

O algoritmo escolhido foi o **KMeans**, aplicado sobre as variáveis de latitude e longitude, com o objetivo de agrupar sensores geograficamente próximos em zonas urbanas.

Justificativa da abordagem

A escolha do KMeans foi motivada pelos seguintes fatores:

- número reduzido de sensores;
- sensores fixos e já georreferenciados;
- necessidade de criar poucas zonas com interpretação prática;

- facilidade de explicação da metodologia em contexto analítico.

O objetivo da clusterização não foi apenas obter a melhor separação matemática possível, mas encontrar um equilíbrio entre:

- qualidade do agrupamento;
- estabilidade espacial;
- interpretabilidade urbana;
- utilidade prática para análise origem-destino.

Avaliação do número de clusters

Para evitar a escolha arbitrária do número de zonas, foram testados diferentes valores de k , de **3 a 10**, utilizando duas métricas:

- **inércia** (para avaliar compactação dos clusters);
- **silhouette score** (para avaliar separação entre grupos).

Métricas obtidas

k	Inércia	Silhouette
3	0.008250	0.454253
4	0.006143	0.427184
5	0.004422	0.469589
6	0.002782	0.486162
7	0.002103	0.483646
8	0.001401	0.523444
9	0.001059	0.518703
10	0.000834	0.506174

Embora valores mais altos de k tenham apresentado silhouette ligeiramente superior, optou-se por utilizar **$k = 5$** , pois esse valor apresentou bom desempenho

estatístico e, ao mesmo tempo, manteve a análise mais interpretável e menos fragmentada.

Em um contexto aplicado, aumentar excessivamente o número de clusters poderia gerar zonas muito pequenas, dificultando a leitura dos fluxos e tornando a matriz origem-destino menos intuitiva.

Procedimento realizado

A Fase 3 foi conduzida em quatro passos principais:

1. extração da tabela de sensores únicos;
2. teste de diferentes valores de k para clusterização;
3. geração da tabela final de sensores clusterizados;
4. associação da zona correspondente a cada evento da base original.

Ao final do processo, cada leitura de tráfego passou a ter também uma variável espacial agregada, representando a zona à qual o sensor pertence.

Arquivos gerados

Ao final da etapa, foram produzidos os seguintes arquivos:

Base de sensores únicos

sensores_unicos.parquet

Base de sensores com zona atribuída

sensores_clusterizados.parquet

Base completa de eventos com zona associada

eventos_com_zona.parquet

Arquivos auxiliares de avaliação

- **metricas_kmeans.csv**
- **grafico_elbow_silhouette.png**

Resultado da clusterização

Sensores únicos identificados

- **26 sensores**

Número final de zonas adotado

- **5 zonas**

Resumo final da base com zona

- **Total de eventos:** 21.061.609
 - **Total de sensores:** 26
 - **Total de zonas:** 5
-

Distribuição dos sensores por zona

A distribuição final dos sensores entre as cinco zonas foi:

- **Zona 1:** 8 sensores
- **Zona 2:** 2 sensores
- **Zona 3:** 8 sensores
- **Zona 4:** 5 sensores
- **Zona 5:** 3 sensores

Essa distribuição mostra que as zonas não ficaram perfeitamente equilibradas em número de sensores, o que é esperado em dados espaciais reais, já que os sensores não estão uniformemente distribuídos na cidade.

Distribuição dos eventos por zona

Quando a clusterização foi associada à base completa de eventos, obteve-se a seguinte distribuição:

- **Zona 1:** 5.956.448 eventos (**28,28%**)
- **Zona 2:** 1.425.963 eventos (**6,77%**)
- **Zona 3:** 7.787.250 eventos (**36,97%**)
- **Zona 4:** 3.397.020 eventos (**16,13%**)
- **Zona 5:** 2.494.928 eventos (**11,85%**)

A **Zona 3** concentrou o maior volume de eventos, sugerindo maior intensidade de tráfego ou presença de sensores em pontos mais movimentados. Já a **Zona**

2 apresentou a menor participação relativa, mas ainda com volume suficiente para análise.

Validação da etapa

1. Todos os eventos receberam zona

A validação mostrou:

- **eventos sem zona = 0**
- **eventos sem nome de zona = 0**

Isso confirma que todos os sensores presentes na base original foram corretamente mapeados para uma zona, e que não houve perda de informação espacial na junção.

2. Coerência da estrutura final

A base `eventos_com_zona.parquet` manteve todas as colunas analíticas já criadas anteriormente e recebeu duas novas variáveis:

- `zona`
- `zona_nome`

Essas colunas passam a ser essenciais para as próximas fases do projeto.

3. Principais sensores por volume

Entre os sensores com maior quantidade de eventos, destacaram-se:

- 1078 — Zona 3 — 1.553.458 eventos
- 1017 — Zona 4 — 1.522.863 eventos
- 1021 — Zona 1 — 1.457.237 eventos
- 1081 — Zona 3 — 1.400.867 eventos
- 1019 — Zona 3 — 1.293.465 eventos

Esses resultados sugerem que algumas zonas concentram sensores de maior fluxo, o que poderá influenciar os padrões de origem-destino observados posteriormente.

Interpretação dos resultados

A clusterização foi bem-sucedida em transformar a malha de sensores em um conjunto mais manejável de regiões urbanas. Com isso, o projeto deixa de operar apenas no nível de sensores individuais e passa a trabalhar em um nível espacial mais agregado, que é mais apropriado para análise de mobilidade.

Essa transformação é metodologicamente importante porque:

- reduz ruído analítico;
- melhora a interpretabilidade dos deslocamentos;
- facilita a visualização dos fluxos;
- prepara diretamente a base para definição de origem e destino por zona.

Limitações observadas

Apesar do bom resultado, algumas limitações devem ser registradas:

- a clusterização foi baseada apenas em latitude e longitude;
- não foram incorporadas informações da rede viária, barreiras físicas ou uso do solo;
- a escolha de $k=5$ envolve um componente analítico de interpretabilidade, não apenas otimização matemática;
- algumas zonas ficaram mais representadas que outras em número de eventos.

Essas limitações, no entanto, não comprometem a utilidade da etapa, pois o objetivo principal é criar agregações espaciais operacionais e não reproduzir divisões administrativas formais da cidade.

Conclusão da fase

A Fase 3 cumpriu com sucesso o objetivo de agrupar os sensores em zonas espaciais interpretáveis e anexar essa informação à base completa de eventos.

O principal resultado da etapa foi a criação de uma representação espacial agregada da cidade, fundamental para que os deslocamentos observados possam ser analisados em termos de fluxos entre regiões e não apenas entre sensores isolados.

Com isso, a base está pronta para a próxima etapa, que será a definição de origem e destino de cada veículo em janelas temporais.

Entrega da Fase 3

A entrega desta fase consiste em:

- tabela de sensores únicos;
- tabela de sensores clusterizados em zonas;
- base completa de eventos com zona associada;
- avaliação do número de clusters;
- documentação da escolha metodológica de $k=5$;
- validação da atribuição espacial.

Fase 4 — Definição de Origem e Destino

Objetivo

A Fase 4 teve como objetivo transformar a base de eventos georreferenciados em uma base de pares origem-destino (O-D), permitindo representar deslocamentos observados em termos de zonas de partida e chegada.

Essa etapa é central para o projeto, pois cria a variável analítica principal que será utilizada nas fases seguintes para construção da matriz O-D, análise de fluxos entre regiões e modelagem probabilística dos deslocamentos urbanos.

Descrição da etapa

Após a clusterização dos sensores realizada na Fase 3, cada evento de passagem passou a estar associado a uma zona espacial da cidade. A partir dessa base enriquecida, foi necessário definir uma regra operacional para identificar origem e destino dos veículos.

Como a base de transições da Fase 2 revelou que muitos eventos consecutivos da mesma placa possuem intervalos muito longos, optou-se por uma estratégia mais restritiva e consistente: segmentar os registros por veículo, por data e por período do dia.

Dessa forma, cada conjunto de eventos pertencente à mesma combinação de:

- placa;
- data;
- período do dia

foi tratado como uma sessão analítica O-D.

Dentro de cada sessão, foram definidos:

- **origem:** primeira zona observada no período;
- **destino:** última zona observada no período.

Essa abordagem evita unir registros de dias diferentes ou de períodos muito distantes entre si, tornando a inferência de deslocamento mais coerente com a dinâmica urbana.

Lógica adotada

A identificação dos pares O-D foi feita a partir da seguinte estrutura de sessão:

sessão O-D = placa + data + período do dia

Para cada sessão:

1. os eventos foram ordenados cronologicamente;
2. o primeiro evento da sessão definiu a origem;
3. o último evento da sessão definiu o destino;
4. também foram calculadas métricas auxiliares da sessão, como:
 - quantidade de eventos;
 - quantidade de sensores distintos;
 - quantidade de zonas distintas;
 - duração total da sessão em minutos.

Além disso, foi criada uma variável indicadora para classificar cada par como:

- **intra-zona:** origem e destino na mesma zona;
- **inter-zona:** origem e destino em zonas diferentes.

Arquivos gerados

Ao final da fase, foram produzidos dois arquivos principais:

Base de eventos com identificador de sessão O-D

eventos_sesoes_od.parquet

Base consolidada de pares origem-destino

pares_od.parquet

Resultado da etapa

Resumo geral

A aplicação da regra de sessão por veículo, data e período do dia gerou os seguintes resultados:

- **Total de pares O-D:** 15.574.169
- **Total de placas distintas:** 1.440.237
- **Total de dias distintos:** 113

- **Total de períodos do dia:** 4
- **Pares intra-zona:** 13.708.632
- **Pares inter-zona:** 1.865.537

Esses números mostram que a base foi construída com sucesso e possui volume suficiente para análise de fluxos entre zonas.

Validação da Fase 4

1. Consistência estrutural

A validação mostrou que a base pares_od.parquet foi criada corretamente, contendo todas as variáveis esperadas para representar os pares O-D e suas características temporais e espaciais.

As colunas principais da base incluem:

- placa
- data
- periodo_dia
- zona_origem
- zona_destino
- timestamp_inicio
- timestamp_fim
- qtd_eventos
- qtd_sensores_distintos
- qtd_zonas_distintas
- duracao_minutos
- intra_zona

2. Nulos nas colunas principais

Não foram encontrados valores nulos nas colunas essenciais da base de pares O-D:

- placa_nula = 0
- data_nula = 0

- periodo_nulo = 0
- origem_nula = 0
- destino_nulo = 0
- inicio_nulo = 0
- fim_nulo = 0

Isso confirma a consistência lógica da geração da base.

Distribuição por período do dia

A distribuição dos pares O-D por período ficou assim:

- **Tarde:** 5.763.265 pares (**37,01%**)
- **Manhã:** 5.130.902 pares (**32,94%**)
- **Noite:** 3.872.459 pares (**24,86%**)
- **Madrugada:** 807.543 pares (**5,19%**)

Esse comportamento é coerente com a dinâmica temporal já observada nas fases anteriores, com maior concentração de registros durante os períodos mais ativos da mobilidade urbana.

Distribuição intra-zona vs inter-zona

A classificação dos pares mostrou:

- **88,02%** dos pares são **intra-zona**
- **11,98%** dos pares são **inter-zona**

Esse resultado é importante e deve ser interpretado com cautela. A predominância de pares intra-zona não significa necessariamente ausência de deslocamentos entre regiões, mas sim que muitos veículos foram observados poucas vezes dentro de cada sessão definida.

Quantidade de eventos por sessão O-D

A análise da quantidade de eventos em cada sessão mostrou:

- **1 evento:** 11.737.431 sessões (**75,36%**)
- **2 eventos:** 2.739.259 sessões (**17,59%**)

- **3 a 5 eventos:** 1.051.075 sessões (**6,75%**)
- **6 a 10 eventos:** 45.727 sessões (**0,29%**)
- **mais de 10 eventos:** 677 sessões

Esse resultado explica a alta concentração de pares intra-zona: quando uma sessão possui apenas um único evento, a origem e o destino são necessariamente a mesma zona.

Ao mesmo tempo, o número de sessões com múltiplos eventos ainda é expressivo e suficiente para gerar fluxos inter-zona relevantes.

Duração das sessões

As estatísticas de duração das sessões foram:

- **mínimo:** 0 minutos
- **máximo:** 359 minutos
- **média:** 18,14 minutos
- **mediana:** 0 minutos

Percentis:

- **p25:** 0 minutos
- **p75:** 0 minutos
- **p90:** 63 minutos
- **p95:** 145 minutos
- **p99:** 267 minutos

A mediana igual a zero reforça a constatação de que grande parte das sessões possui apenas um único evento. Ainda assim, os percentis mais altos mostram que existe uma parcela relevante de sessões com duração observável e potencial de capturar deslocamentos entre zonas.

Quantidade de zonas distintas por sessão

A contagem de zonas distintas por sessão indicou:

- **1 zona distinta:** 13.511.523 sessões (**86,76%**)
- **2 zonas distintas:** 1.881.525 sessões (**12,08%**)

- **3 zonas distintas:** 165.376 sessões (**1,06%**)
- **4 zonas distintas:** 14.865 sessões (**0,10%**)
- **5 zonas distintas:** 880 sessões (**0,01%**)

Esses valores mostram que a maioria das sessões permanece restrita a uma única zona, mas também revelam uma quantidade significativa de sessões que atravessam duas ou mais zonas.

Principais fluxos inter-zona

Entre os fluxos inter-zona mais frequentes, destacam-se:

- **Zona 3 → Zona 1 (tarde):** 246.108 pares
- **Zona 3 → Zona 1 (manhã):** 175.048 pares
- **Zona 3 → Zona 1 (noite):** 163.027 pares
- **Zona 4 → Zona 2 (tarde):** 69.830 pares
- **Zona 1 → Zona 5 (tarde):** 66.575 pares
- **Zona 1 → Zona 3 (tarde):** 62.238 pares

Esses resultados já indicam padrões relevantes de circulação entre zonas e sugerem a existência de conexões recorrentes entre determinadas regiões da cidade.

O fluxo **Zona 3 → Zona 1** aparece como o mais importante em diferentes períodos do dia, o que pode representar um corredor urbano de forte intensidade.

Interpretação dos resultados

A Fase 4 foi bem-sucedida ao gerar uma base estruturada de pares origem-destino a partir de uma regra simples, coerente e operacional.

Além de produzir a variável alvo do projeto, essa fase também revelou uma característica importante da base: a maior parte das sessões possui apenas um único evento observado. Isso mostra que a rede de sensores, embora útil, oferece cobertura parcial da mobilidade urbana, o que limita a reconstrução completa dos deslocamentos.

Mesmo assim, a base final contém **1.865.537 pares inter-zona**, volume mais do que suficiente para construção da matriz O-D e análise dos principais fluxos urbanos.

Portanto, a etapa não apenas cumpriu seu objetivo, como também forneceu uma leitura realista das limitações e do potencial do conjunto de dados.

Limitações observadas

As principais limitações identificadas nesta fase foram:

- predominância de sessões com apenas um evento;
- alta proporção de pares intra-zona;
- dependência da cobertura espacial limitada dos sensores;
- impossibilidade de reconstruir trajetórias completas para grande parte dos veículos.

Essas limitações são coerentes com a natureza do problema e devem ser explicitadas na interpretação dos resultados.

Conclusão da fase

A Fase 4 cumpriu com sucesso o objetivo de definir origem e destino dos veículos dentro de sessões temporais coerentes, gerando a base principal de pares O-D do projeto.

Essa etapa marca a transição do projeto de uma base de eventos para uma base efetivamente analítica de deslocamentos entre zonas. Com isso, os dados estão prontos para a próxima fase, em que será construída a matriz origem-destino por período do dia.

Entrega da Fase 4

A entrega desta fase consiste em:

- base de eventos com identificador de sessão O-D;
- base consolidada de pares origem-destino;
- definição operacional de origem e destino por veículo, data e período;
- classificação intra-zona e inter-zona;
- validação da qualidade e da estrutura dos pares gerados.

Fase 5 — Construção da Matriz Origem-Destino

Objetivo

A Fase 5 teve como objetivo gerar o principal produto analítico do projeto: a **matriz origem-destino (O-D)** por período do dia.

A matriz O-D representa a quantidade de deslocamentos observados entre zonas da cidade, permitindo identificar os principais fluxos urbanos e analisar como esses padrões variam ao longo do tempo.

Além da matriz em valores absolutos, também foi gerada uma versão normalizada em termos probabilísticos, permitindo interpretar a probabilidade de um veículo ter determinado destino, dado sua origem e o período do dia.

Descrição da etapa

A partir da base de pares O-D construída na Fase 4, os registros foram agregados por:

- periodo_dia
- zona_origem
- zona_destino

Essa agregação permitiu contar quantos deslocamentos foram observados para cada combinação origem-destino em cada período.

Em seguida, os resultados foram organizados em duas formas complementares:

1. **matriz absoluta**, contendo o número total de fluxos por origem e destino;
2. **matriz probabilística**, contendo a probabilidade condicional:

$$P(\text{destino} \mid \text{origem}, \text{periodo})$$

Nessa matriz probabilística, cada linha representa uma zona de origem em um determinado período, e a soma das probabilidades dos destinos dessa linha é igual a 1.

Lógica adotada

A construção da matriz foi feita em três etapas:

1. Contagem de fluxos

Cada par O-D da fase anterior foi contabilizado de acordo com:

- período do dia;
- zona de origem;
- zona de destino.

2. Geração da matriz absoluta

Os fluxos contados foram reorganizados em formato matricial, onde:

- cada linha representa uma zona de origem;
- cada coluna representa uma zona de destino;
- o valor da célula corresponde à quantidade de deslocamentos observados.

3. Normalização probabilística

Para cada combinação de período e zona de origem, os fluxos foram divididos pela soma total dos fluxos daquela origem, gerando a probabilidade de cada destino.

Essa etapa produz uma interpretação muito importante para análise urbana:

- dado que um deslocamento começa em determinada zona e período, qual é a distribuição provável de destinos observados?

Arquivos gerados

Ao final da Fase 5, foram gerados os seguintes arquivos principais:

Bases processadas

- **fluxos_od.parquet**
- **matriz_od_absoluta.parquet**
- **matriz_od_probabilidade.parquet**

Arquivos de saída em CSV por período

Matrizes absolutas

- **matriz_od_absoluta_madrugada.csv**
- **matriz_od_absoluta_manha.csv**
- **matriz_od_absoluta_tarde.csv**
- **matriz_od_absoluta_noite.csv**

Matrizes probabilísticas

- matriz_od_probabilidade_madrugada.csv
 - matriz_od_probabilidade_manha.csv
 - matriz_od_probabilidade_tarde.csv
 - matriz_od_probabilidade_noite.csv
-

Resultado da etapa

Resumo geral

A Fase 5 gerou:

- **100 fluxos O-D**
- **4 períodos do dia**
- **5 zonas de origem**
- **5 zonas de destino**
- **15.574.169 fluxos totais contabilizados**

O número total de fluxos coincide exatamente com o número de pares O-D produzidos na Fase 4, confirmando a consistência da agregação.

Além disso, o total de combinações possíveis também é coerente com a estrutura do problema:

$$4 \text{ períodos} \times 5 \text{ origens} \times 5 \text{ destinos} = 100$$

Validação da Fase 5

1. Estrutura dos arquivos

A validação confirmou que:

- a tabela de fluxos O-D foi criada com as colunas esperadas;
- a matriz absoluta possui uma linha para cada combinação de período e origem;
- a matriz probabilística apresenta a mesma estrutura da matriz absoluta, com valores normalizados.

As colunas da tabela de fluxos foram:

- periodo_dia

- zona_origem
 - zona_destino
 - qtd_fluxos
 - prob_destino_dado_origem
-

2. Soma das probabilidades

A validação mostrou que, para cada combinação de periodo_dia e zona_origem, a soma das probabilidades dos destinos é aproximadamente igual a 1.

Exemplos:

- madrugada, origem 1 → **1.000000**
- manhã, origem 3 → **1.000000**
- tarde, origem 4 → **1.000000**
- noite, origem 5 → **0.999999**

As pequenas variações observadas, como 0.999999 ou 1.000001, são decorrentes apenas de arredondamento numérico e não representam inconsistência do modelo.

Principais fluxos observados

Fluxos absolutos mais intensos

Os maiores fluxos observados foram predominantemente intra-zona, com destaque para:

- **Tarde, Zona 3 → Zona 3:** 1.781.804
- **Manhã, Zona 3 → Zona 3:** 1.635.431
- **Tarde, Zona 1 → Zona 1:** 1.498.734
- **Manhã, Zona 1 → Zona 1:** 1.344.530
- **Noite, Zona 3 → Zona 3:** 1.125.041
- **Noite, Zona 1 → Zona 1:** 974.286

Esse resultado é coerente com a fase anterior, na qual a maioria dos pares O-D foi classificada como intra-zona.

Principais fluxos inter-zona

Apesar da predominância intra-zona, a análise revelou fluxos inter-zona importantes:

- **Tarde, Zona 3 → Zona 1:** 246.108
- **Manhã, Zona 3 → Zona 1:** 175.048
- **Noite, Zona 3 → Zona 1:** 163.027
- **Tarde, Zona 4 → Zona 2:** 69.830
- **Tarde, Zona 1 → Zona 5:** 66.575
- **Tarde, Zona 1 → Zona 3:** 62.238

O fluxo **Zona 3 → Zona 1** aparece como o principal deslocamento inter-zona observado em múltiplos períodos, sugerindo a existência de um corredor ou relação espacial forte entre essas duas regiões.

Interpretação probabilística

A matriz probabilística permitiu transformar os fluxos absolutos em uma leitura mais analítica do comportamento observado.

Por exemplo, na **tarde**, para veículos com origem na **Zona 3**, a distribuição de destinos foi:

- **Zona 3:** 0,833723
- **Zona 1:** 0,115156
- **Zona 4:** 0,027997
- **Zona 5:** 0,013954
- **Zona 2:** 0,009170

Isso significa que, entre os deslocamentos observados com origem na Zona 3 durante a tarde:

- cerca de **83,37%** permaneceram na própria Zona 3;
- cerca de **11,52%** seguiram para a Zona 1;
- os demais se distribuíram entre outras zonas com participação menor.

Esse tipo de interpretação é especialmente útil para as próximas etapas de modelagem probabilística.

Matrizes resultantes

Exemplo de matriz O-D absoluta

A estrutura final da matriz absoluta foi organizada com:

- linhas = origem
- colunas = destino
- valor = quantidade de fluxos

Exemplo de matriz O-D probabilística

Na matriz probabilística:

- linhas = origem
- colunas = destino
- valor = probabilidade de destino dado origem e período

Essas matrizes foram exportadas separadamente para cada período do dia, facilitando análises comparativas e visualizações posteriores.

Interpretação dos resultados

A Fase 5 cumpriu com sucesso o objetivo central de transformar os pares origem-destino em matrizes analíticas de fluxo urbano.

O resultado mostra que:

- os deslocamentos observados possuem forte componente intra-zona;
- ainda assim, existem fluxos inter-zona relevantes e consistentes;
- determinados pares de zonas apresentam padrões recorrentes em diferentes períodos do dia;
- a representação probabilística adiciona uma camada importante de interpretação ao problema.

Essa etapa representa o núcleo analítico do projeto e prepara diretamente o terreno para a fase seguinte de modelagem probabilística.

Limitações observadas

As principais limitações da Fase 5 derivam das fases anteriores:

- predominância de pares intra-zona devido a muitas sessões com apenas um evento;
- cobertura espacial limitada da rede de sensores;
- matriz baseada em deslocamentos observados e inferidos, não em trajetórias completas;
- probabilidade condicionada ao conjunto monitorado, e não à mobilidade total da cidade.

Essas limitações não inviabilizam a análise, mas devem ser explicitadas na interpretação do produto final.

Conclusão da fase

A Fase 5 gerou com sucesso a matriz origem-destino por período do dia, tanto em formato absoluto quanto probabilístico.

Essa matriz representa o principal produto do projeto até este ponto, pois consolida a inferência de mobilidade urbana em uma estrutura capaz de revelar fluxos recorrentes, probabilidades de deslocamento e relações espaciais entre regiões da cidade.

Com isso, a base está pronta para a próxima etapa, em que será desenvolvida a modelagem probabilística dos fluxos observados.

Entrega da Fase 5

A entrega desta fase consiste em:

- tabela consolidada de fluxos origem-destino;
- matrizes O-D absolutas por período;
- matrizes O-D probabilísticas por período;
- arquivos CSV prontos para visualização e análise;
- validação da consistência probabilística do modelo.

Copilot said: Perfeito — com essa validação, a **Fase

Perfeito — com essa validação, a **Fase 6 está concluída.**

O que essa fase agregou ao projeto

A Fase 6 consolidou de vez a parte probabilística em dois níveis diferentes:

1. Nível agregado O-D

Modela:

$$P(\text{destino} \mid \text{origem}, \text{periodo})$$

2. Nível sequencial Markoviano

Modela:

$$P(\text{proxima}_{\text{zona}} \mid \text{zona}_{\text{atual}}, \text{periodo})$$

Esse segundo nível é um ganho metodológico importante, porque passa a representar a mobilidade como uma sequência de transições observadas, e não apenas como um par origem-destino resumido.

Principais resultados da Fase 6

Estrutura geral

- **100 linhas no modelo probabilístico O-D**
- **5.487.440 transições Markov**
- **3.836.738 sessões com pelo menos uma transição**
- **100 linhas na matriz Markov absoluta**
- **100 linhas na matriz Markov probabilística**

Isso mostra que a fase gerou uma base sequencial robusta.

Destino mais provável por origem e período

Em todos os casos, o destino mais provável continua sendo a própria zona de origem:

- madrugada: $1 \rightarrow 1 = \mathbf{0,929107}$
- manhã: $1 \rightarrow 1 = \mathbf{0,928732}$

- noite: $5 \rightarrow 5 = 0,922573$
- tarde: $3 \rightarrow 3 = 0,833723$

Isso é coerente com as fases anteriores, especialmente:

- alta proporção de pares intra-zona
 - predominância de sessões curtas
-

Destinos alternativos relevantes

O rank 2 revelou padrões importantes:

- $3 \rightarrow 1$ aparece com muita força em todos os períodos:
 - noite = **0,120232**
 - tarde = **0,115156**
 - madrugada = **0,114918**
 - manhã = **0,093136**
- $2 \rightarrow 4$ também aparece forte:
 - manhã = **0,082069**
 - madrugada = **0,079873**
 - tarde = **0,069664**
 - noite = **0,072623**

Esses padrões confirmam relações espaciais consistentes entre algumas zonas.

Estatísticas das transições Markov

- **5.487.440 transições**
- **3.836.738 sessões com transição**
- **média de delta: 51,48 minutos**
- **mediana de delta: 17 minutos**

Isso é um resultado muito interessante.

Interpretação

Na Fase 2, os deltas gerais entre eventos consecutivos por placa eram enormes, porque atravessavam muitos contextos temporais diferentes.

Agora, dentro da estrutura de sessão:

- a mediana caiu para **17 minutos**
- a média ficou em **51,48 minutos**

Ou seja, a segmentação feita nas fases anteriores melhorou bastante a coerência temporal para análise sequencial.

Transições Markov mais fortes

As mais frequentes foram:

- tarde: $3 \rightarrow 3 = 625.709$
- manhã: $3 \rightarrow 3 = 500.890$
- noite: $3 \rightarrow 3 = 353.051$
- tarde: $3 \rightarrow 1 = 327.825$
- tarde: $1 \rightarrow 1 = 301.606$

Isso mostra que:

- a permanência na própria zona ainda é importante
- mas certas transições inter-zona são muito expressivas

Principais transições inter-zona

Destaques:

- tarde: $3 \rightarrow 1 = 327.825 (0,302904)$
- manhã: $3 \rightarrow 1 = 234.365 (0,285568)$
- noite: $3 \rightarrow 1 = 212.552 (0,329880)$
- tarde: $1 \rightarrow 3 = 126.086 (0,236420)$
- manhã: $1 \rightarrow 3 = 98.437 (0,255982)$
- tarde: $4 \rightarrow 2 = 95.309 (0,261929)$
- manhã: $2 \rightarrow 4 = 40.775 (0,446473)$

Esses resultados sugerem conexões direcionais muito relevantes entre zonas específicas.

Texto pronto da documentação da Fase 6

Você pode usar o texto abaixo no relatório, notebook ou documentação da fase.

Fase 6 — Modelagem Probabilística dos Fluxos

Objetivo

A Fase 6 teve como objetivo adicionar uma camada probabilística à análise dos deslocamentos urbanos, transformando os fluxos observados em modelos capazes de representar tanto os destinos mais prováveis quanto as transições sequenciais entre zonas.

Essa etapa amplia o escopo analítico do projeto em duas direções complementares:

1. **modelo probabilístico agregado de origem-destino**, baseado na distribuição de destinos observados para cada origem e período;
2. **modelo sequencial Markoviano**, baseado nas transições observadas entre zonas consecutivas dentro das sessões dos veículos.

Com isso, o projeto deixa de oferecer apenas contagens de fluxos e passa a representar o comportamento espacial dos veículos em termos de probabilidade.

Descrição da etapa

A Fase 6 utilizou como entrada dois produtos gerados anteriormente:

- a base de sessões com eventos ordenados (eventos_sessoes_od.parquet);
- a tabela de fluxos O-D por origem, destino e período (fluxos_od.parquet).

A partir desses arquivos, a fase foi estruturada em dois blocos principais.

Bloco 1 — Modelo probabilístico O-D

Nesse bloco, os fluxos entre zonas gerados na Fase 5 foram enriquecidos com:

- ranking dos destinos mais prováveis por origem e período;
- identificação do destino dominante;
- exportação dos três principais destinos por origem/período.

Bloco 2 — Modelo de transição Markoviana

Nesse bloco, foi utilizada a sequência cronológica dos eventos dentro de cada sessão para identificar pares do tipo:

- zona atual;
- próxima zona observada.

Essas transições foram agregadas por período do dia e transformadas em uma matriz probabilística de 1ª ordem, representando:

$$P(\text{proxima}_{\text{zona}} | \text{zona}_{\text{atual}}, \text{periodo})$$

Esse modelo descreve a mobilidade como uma cadeia de transições sucessivas entre zonas, capturando o comportamento observável ao longo do percurso.

Arquivos gerados

Ao final da fase, foram produzidos os seguintes arquivos:

Bases processadas

- `modelo_prob_od.parquet`
- `transicoes_markov.parquet`
- `matriz_markov_absoluta.parquet`
- `matriz_markov_probabilidade.parquet`

Arquivos CSV exportados

- `top_destinos_por_origem_periodo.csv`
 - `matriz_markov_absoluta.csv`
 - `matriz_markov_probabilidade.csv`
-

Resultado da etapa

Resumo geral

A Fase 6 gerou:

- **100 linhas no modelo probabilístico O-D**
- **5.487.440 transições Markov**

- **3.836.738 sessões com pelo menos uma transição**
- **100 linhas na matriz Markov absoluta**
- **100 linhas na matriz Markov probabilística**

A quantidade de linhas da matriz Markov é coerente com a estrutura das combinações possíveis entre:

- 4 períodos do dia
- 5 zonas atuais
- 5 próximas zonas

$$4 \times 5 \times 5 = 100$$

Modelo probabilístico O-D

Destino mais provável

A validação mostrou que, para todas as combinações de origem e período, o destino mais provável corresponde à própria zona de origem.

Exemplos:

- madrugada, **1 → 1** = 0,929107
- manhã, **1 → 1** = 0,928732
- noite, **5 → 5** = 0,922573
- tarde, **3 → 3** = 0,833723

Esse comportamento é coerente com as fases anteriores, nas quais predominavam pares intra-zona e sessões curtas.

Destinos alternativos

Apesar da dominância da diagonal, os destinos alternativos mais prováveis revelaram relações espaciais relevantes.

Entre os principais casos de rank 2, destacam-se:

- **3 → 1**
 - noite = 0,120232
 - tarde = 0,115156
 - madrugada = 0,114918

- manhã = 0,093136
- **2 → 4**
 - manhã = 0,082069
 - madrugada = 0,079873
 - noite = 0,072623
 - tarde = 0,069664

Esses padrões mostram que algumas zonas apresentam conexões recorrentes e persistentes em diferentes períodos do dia.

Modelo Markoviano

Construção das transições

As transições Markov foram definidas com base nos eventos consecutivos observados dentro de cada sessão O-D. Para cada evento, foi identificado o próximo evento da mesma sessão, gerando pares do tipo:

- zona_atual
- proxima_zona

A partir desses pares, foram calculadas:

- a matriz absoluta de transições;
- a matriz probabilística de transições.

Estatísticas gerais

A análise das transições resultou em:

- **5.487.440 transições**
- **3.836.738 sessões com transição**
- **5 zonas atuais distintas**
- **5 próximas zonas distintas**
- **média do intervalo entre transições:** 51,48 minutos
- **mediana do intervalo entre transições:** 17 minutos

Esses números são metodologicamente importantes. Em comparação com a Fase 2, na qual os intervalos entre eventos consecutivos eram muito altos, a definição

de sessões aplicada nas fases seguintes reduziu significativamente a dispersão temporal, tornando a modelagem sequencial mais coerente.

Validação probabilística

A validação mostrou que, para cada combinação de período do dia e zona atual, a soma das probabilidades das próximas zonas é aproximadamente igual a 1.

Exemplos:

- madrugada, zona atual 1 → **1.000001**
- manhã, zona atual 3 → **1.000000**
- noite, zona atual 3 → **0.999999**
- tarde, zona atual 5 → **1.000001**

As pequenas variações observadas decorrem apenas de arredondamento numérico.

Principais transições Markov

Entre as transições mais frequentes, destacam-se:

- tarde: **3 → 3** = 625.709
- manhã: **3 → 3** = 500.890
- noite: **3 → 3** = 353.051
- tarde: **3 → 1** = 327.825
- tarde: **1 → 1** = 301.606

Esses resultados mostram que a permanência na própria zona continua relevante, mas as transições inter-zona aparecem de forma mais explícita do que no modelo O-D agregado.

Principais transições inter-zona

As transições inter-zona mais importantes foram:

- tarde: **3 → 1** = 327.825 (**0,302904**)
- manhã: **3 → 1** = 234.365 (**0,285568**)
- noite: **3 → 1** = 212.552 (**0,329880**)

- tarde: $1 \rightarrow 3 = 126.086$ (**0,236420**)
- manhã: $1 \rightarrow 3 = 98.437$ (**0,255982**)
- tarde: $4 \rightarrow 2 = 95.309$ (**0,261929**)
- manhã: $2 \rightarrow 4 = 40.775$ (**0,446473**)

Esses resultados revelam conexões direcionais importantes entre algumas zonas, especialmente entre as Zonas 3 e 1, e entre as Zonas 2 e 4.

Interpretação dos resultados

A Fase 6 foi bem-sucedida ao transformar os fluxos observados em uma estrutura probabilística mais sofisticada.

Enquanto a Fase 5 representava a mobilidade em termos de pares origem-destino agregados, a Fase 6 adiciona uma dimensão sequencial, mais próxima do comportamento real de deslocamento.

Essa distinção é importante:

- o **modelo O-D agregado** resume a relação entre início e fim da sessão;
- o **modelo Markoviano** representa o encadeamento entre passos consecutivos observados.

Com isso, o projeto passa a oferecer duas leituras complementares da mobilidade urbana:

- uma leitura agregada;
 - uma leitura sequencial.
-

Limitações observadas

As limitações da Fase 6 decorrem principalmente da natureza dos dados observados:

- os sensores capturam apenas pontos discretos da cidade;
- as transições observadas não representam necessariamente o trajeto completo;
- a cadeia de Markov adotada é de primeira ordem e considera apenas a próxima zona;

- a probabilidade estimada reflete o comportamento observado na rede monitorada, não toda a mobilidade urbana.

Ainda assim, a modelagem probabilística produzida é plenamente útil para análise exploratória, inferência de padrões e apoio a decisões em mobilidade urbana.

Conclusão da fase

A Fase 6 cumpriu com sucesso o objetivo de construir a camada probabilística do projeto.

Ao final da etapa, o trabalho passou a contar com:

- um modelo probabilístico de destinos por origem e período;
- um ranking de destinos mais prováveis;
- uma matriz de transição Markoviana entre zonas;
- uma representação sequencial probabilística da mobilidade observada.

Essa fase consolida o núcleo analítico do projeto e prepara a base para possíveis extensões futuras, como simulação de trajetórias, previsão do próximo destino ou visualizações interativas dos fluxos probabilísticos.

Entrega da Fase 6

A entrega desta fase consiste em:

- modelo probabilístico O-D com ranking de destinos;
- base de transições sequenciais entre zonas;
- matriz Markov absoluta;
- matriz Markov probabilística;
- exportação dos resultados em CSV;
- validação da consistência probabilística do modelo.

Fase 7 — Visualização e Consolidação dos Resultados

Objetivo

A Fase 7 teve como objetivo consolidar os resultados analíticos produzidos nas etapas anteriores e convertê-los em saídas visuais e tabelas de apoio à interpretação final do projeto.

Depois da construção da base limpa, da estruturação temporal por veículo, da clusterização dos sensores, da definição de origem-destino, da geração da matriz O-D e da modelagem probabilística, tornou-se necessário organizar os resultados em um formato mais adequado para leitura analítica, comunicação e apresentação.

Essa fase representa a etapa de fechamento operacional do pipeline, na qual os principais padrões identificados ao longo do projeto foram sintetizados em indicadores executivos, rankings e visualizações gráficas.

Descrição da etapa

A Fase 7 utilizou como insumo os principais produtos das Fases 5 e 6, especialmente:

- tabela de fluxos origem-destino;
- matriz O-D absoluta;
- matriz O-D probabilística;
- modelo probabilístico de destinos;
- matriz Markov probabilística.

Com base nesses arquivos, foram gerados:

- resumo executivo por período do dia;
- ranking dos principais fluxos inter-zona;
- ranking das principais transições Markov inter-zona;
- tabela dos destinos alternativos mais prováveis;
- heatmaps das matrizes O-D absolutas;
- heatmaps das matrizes O-D probabilísticas;
- heatmaps das matrizes Markov probabilísticas;
- gráficos de barras com os principais fluxos identificados.

Essa estrutura permitiu transformar os resultados numéricos em artefatos de interpretação direta, adequados para relatório final, apresentação acadêmica ou uso exploratório posterior.

Produtos gerados

Arquivos processados

Foram produzidos os seguintes arquivos tabulares:

- **resumo_executivo_periodo.csv**
- **top_fluxos_interzona.csv**
- **top_markov_interzona.csv**
- **destinos_alternativos.csv**

Arquivos visuais

Também foram produzidos **14 arquivos PNG**, organizados da seguinte forma:

Heatmaps da matriz O-D absoluta

- heatmap_od_absoluta_madrugada.png
- heatmap_od_absoluta_manha.png
- heatmap_od_absoluta_tarde.png
- heatmap_od_absoluta_noite.png

Heatmaps da matriz O-D probabilística

- heatmap_od_prob_madrugada.png
- heatmap_od_prob_manha.png
- heatmap_od_prob_tarde.png
- heatmap_od_prob_noite.png

Heatmaps da matriz Markov probabilística

- heatmap_markov_prob_madrugada.png
- heatmap_markov_prob_manha.png
- heatmap_markov_prob_tarde.png
- heatmap_markov_prob_noite.png

Gráficos de ranking

- top_fluxos_interzona.png
 - top_markov_interzona.png
-

Resumo executivo por período

A consolidação por período do dia resultou nos seguintes indicadores:

Tarde

- **Total de fluxos:** 5.763.265
- **Fluxos intra-zona:** 5.023.223
- **Fluxos inter-zona:** 740.042
- **Percentual inter-zona:** 12,84%

Manhã

- **Total de fluxos:** 5.130.902
- **Fluxos intra-zona:** 4.570.280
- **Fluxos inter-zona:** 560.622
- **Percentual inter-zona:** 10,93%

Noite

- **Total de fluxos:** 3.872.459
- **Fluxos intra-zona:** 3.397.393
- **Fluxos inter-zona:** 475.066
- **Percentual inter-zona:** 12,27%

Madrugada

- **Total de fluxos:** 807.543
 - **Fluxos intra-zona:** 717.736
 - **Fluxos inter-zona:** 89.807
 - **Percentual inter-zona:** 11,12%
-

Interpretação do resumo executivo

A análise consolidada mostrou que:

- a **tarde** foi o período com maior volume total de deslocamentos observados;
- a **manhã** apresentou o segundo maior volume de fluxos;
- a **noite** manteve intensidade relevante, com percentual inter-zona semelhante ao da tarde;
- a **madrugada** teve menor volume absoluto, como esperado.

O percentual de deslocamentos inter-zona variou entre **10,93%** e **12,84%**, indicando relativa estabilidade da proporção de fluxos entre zonas ao longo dos períodos do dia.

Esse resultado sugere que, embora o volume absoluto de tráfego mude bastante ao longo do tempo, a estrutura espacial relativa dos deslocamentos observados permanece semelhante.

Principais fluxos inter-zona

A tabela de fluxos inter-zona revelou os principais deslocamentos agregados entre regiões da cidade.

Os maiores fluxos observados foram:

- **Tarde, Zona 3 → Zona 1:** 246.108
- **Manhã, Zona 3 → Zona 1:** 175.048
- **Noite, Zona 3 → Zona 1:** 163.027
- **Tarde, Zona 4 → Zona 2:** 69.830
- **Tarde, Zona 1 → Zona 5:** 66.575
- **Tarde, Zona 1 → Zona 3:** 62.238
- **Tarde, Zona 3 → Zona 4:** 59.834
- **Manhã, Zona 1 → Zona 3:** 53.451
- **Noite, Zona 4 → Zona 2:** 51.989
- **Tarde, Zona 4 → Zona 3:** 45.767

O padrão dominante foi o fluxo **Zona 3 → Zona 1**, que apareceu como o principal deslocamento inter-zona em todos os períodos relevantes.

Principais transições Markov inter-zona

Na abordagem sequencial, baseada em transições entre zonas consecutivas, os maiores padrões observados foram:

- **Tarde, Zona 3 → Zona 1:** 327.825
- **Manhã, Zona 3 → Zona 1:** 234.365
- **Noite, Zona 3 → Zona 1:** 212.552
- **Tarde, Zona 1 → Zona 3:** 126.086
- **Manhã, Zona 1 → Zona 3:** 98.437
- **Tarde, Zona 4 → Zona 2:** 95.309
- **Tarde, Zona 1 → Zona 5:** 89.299
- **Tarde, Zona 3 → Zona 4:** 84.231
- **Noite, Zona 4 → Zona 2:** 69.857
- **Noite, Zona 1 → Zona 3:** 68.628

Esses resultados reforçam o que já havia sido identificado na Fase 6: os mesmos eixos de mobilidade aparecem tanto na matriz origem-destino quanto no modelo Markoviano, o que aumenta a confiabilidade interpretativa dos padrões encontrados.

Destinos alternativos mais prováveis

A tabela de destinos alternativos mostrou qual é o segundo destino mais provável para cada origem e período, ou seja, o principal destino fora da diagonal dominante.

Os casos mais relevantes foram:

- **Noite, origem 3 → destino 1:** 0,120232
- **Tarde, origem 3 → destino 1:** 0,115156
- **Madrugada, origem 3 → destino 1:** 0,114918
- **Manhã, origem 3 → destino 1:** 0,093136
- **Manhã, origem 2 → destino 4:** 0,082069
- **Noite, origem 4 → destino 2:** 0,080726
- **Madrugada, origem 2 → destino 4:** 0,079873
- **Tarde, origem 4 → destino 2:** 0,073861

Esses resultados mostram que, além da permanência intra-zona, existem direções interzonais recorrentes e estáveis ao longo do dia.

Validação da Fase 7

1. Tamanho das tabelas geradas

A validação confirmou o tamanho esperado das principais saídas:

- `resumo_executivo_periodo.csv` → **4 linhas**
- `top_fluxos_interzona.csv` → **20 linhas**
- `top_markov_interzona.csv` → **20 linhas**
- `destinos_alternativos.csv` → **20 linhas**

Esses quantitativos são coerentes com o desenho da fase e com os filtros aplicados para os rankings.

2. Consistência das somas

A soma total dos fluxos no resumo executivo foi:

- **15.574.169**

A decomposição por tipo de fluxo resultou em:

- **Fluxos intra-zona:** 13.708.632
- **Fluxos inter-zona:** 1.865.537

A checagem confirmou que:

$$13.708.632 + 1.865.537 = 15.574.169$$

Isso comprova que a consolidação preservou exatamente os resultados produzidos nas fases anteriores.

3. Cobertura temporal

Todos os períodos do dia apareceram nas principais saídas:

- madrugada
- manhã
- noite
- tarde

Essa cobertura foi confirmada para:

- resumo executivo;
- top fluxos inter-zona;
- top transições Markov inter-zona;
- destinos alternativos.

4. Artefatos visuais

A validação confirmou a geração correta dos **14 arquivos PNG** previstos na etapa. Isso demonstra que a camada visual do projeto foi produzida integralmente.

Interpretação geral dos resultados consolidados

A Fase 7 mostrou que os padrões observados nas fases analíticas anteriores permanecem consistentes quando convertidos em tabelas de síntese e visualizações gráficas.

Os principais achados consolidados foram:

- predominância estrutural de fluxos intra-zona;
- presença de fluxos inter-zona relevantes e persistentes;
- forte centralidade do eixo **Zona 3 → Zona 1**;
- relevância adicional das conexões **Zona 4 ↔ Zona 2** e **Zona 1 ↔ Zona 5**;
- estabilidade do percentual de deslocamentos inter-zona ao longo do dia.

Esses resultados sugerem que, mesmo com cobertura parcial da cidade, o sistema de sensores foi capaz de capturar relações espaciais recorrentes e corredores importantes da mobilidade observada.

Conclusão da fase

A Fase 7 cumpriu com sucesso o objetivo de consolidar os resultados do projeto em formatos analíticos e visuais adequados para interpretação final.

Ao final da etapa, o projeto passou a contar com:

- resumo executivo por período;
- rankings dos principais fluxos inter-zona;
- rankings das principais transições Markov inter-zona;

- tabela de destinos alternativos;
- heatmaps das matrizes O-D e Markov;
- gráficos de apoio à apresentação dos resultados.

Essa fase representa o fechamento analítico e visual do pipeline, tornando os produtos do projeto prontos para uso em relatório final, apresentação acadêmica, artigo ou discussão de resultados.

Entrega da Fase 7

A entrega desta fase consiste em:

- resumo executivo consolidado por período;
- tabelas dos principais fluxos inter-zona;
- tabelas das principais transições Markov inter-zona;
- tabela de destinos alternativos;
- heatmaps das matrizes absolutas e probabilísticas;
- gráficos de consolidação final dos resultados;
- validação da consistência das saídas finais.

Copilot said: Perfeito — a **Fase 8 está validada

Perfeito — a **Fase 8 está validada e concluída.**

Leitura rápida da validação

A fase ficou consistente em todos os pontos principais:

- comparativo_cenarios.csv → **4 linhas**
- comparativo_periodo.csv → **16 linhas**
- top_fluxos_por_cenario.csv → **40 linhas**
- recomendacao_cenario.csv → **4 linhas**

As checagens de consistência também bateram exatamente em todos os cenários:

- $\text{total_pares} = \text{pares_intra} + \text{pares_inter}$

E os 4 gráficos previstos foram gerados corretamente:

- comparativo_pct_interzona.png
- comparativo_por_periodo.png
- comparativo_total_pares.png
- top_fluxos_cenarios.png

Documentação da Fase 8

Você pode usar o texto abaixo no relatório, notebook ou documentação da fase.

Fase 8 — Avaliação de Robustez e Sensibilidade Metodológica

Objetivo

A Fase 8 teve como objetivo avaliar a robustez dos resultados obtidos ao longo do projeto, verificando como a definição dos pares origem-destino se comporta sob diferentes critérios de filtragem.

Até a Fase 7, o pipeline havia produzido uma estrutura completa de análise da mobilidade urbana observada, incluindo:

- pares origem-destino;
- matriz O-D por período;

- modelo probabilístico de destinos;
- cadeia de transição Markoviana;
- visualizações consolidadas.

No entanto, um achado importante das fases anteriores foi a grande quantidade de sessões com apenas um único evento, o que tende a aumentar artificialmente a participação dos fluxos intra-zona e reforçar a diagonal da matriz O-D.

Diante disso, a Fase 8 foi criada para responder a uma questão metodológica central:

os principais padrões observados permanecem estáveis quando mudamos o critério de seleção das sessões?

Descrição da etapa

A Fase 8 utilizou como entrada a base consolidada de pares O-D (pares_od.parquet) e construiu uma comparação entre quatro cenários metodológicos distintos.

Cenário A — Todos os pares

Base completa, sem filtragem adicional.

Cenário B — Sessões com 2 ou mais eventos

Filtro aplicado:

- `qtd_eventos >= 2`

Esse cenário busca remover sessões triviais com apenas um evento observado.

Cenário C — Apenas pares inter-zona

Filtro aplicado:

- `intra_zona = FALSE`

Esse cenário isola exclusivamente deslocamentos entre zonas distintas.

Cenário D — Sessões com duração até 180 minutos

Filtro aplicado:

- `duracao_minutos <= 180`

Esse cenário busca excluir sessões muito longas e potencialmente menos coerentes temporalmente.

Produtos gerados

Arquivos processados

Foram produzidos os seguintes arquivos:

- **comparativo_cenarios.csv**
- **comparativo_periodo.csv**
- **top_fluxos_por_cenario.csv**
- **recomendacao_cenario.csv**

Arquivos gráficos

Também foram produzidos os seguintes gráficos comparativos:

- **comparativo_total_pares.png**
- **comparativo_pct_interzona.png**
- **comparativo_por_periodo.png**
- **top_fluxos_cenarios.png**

Cenários avaliados

A fase comparou os cenários com base nos seguintes indicadores:

- total de pares O-D;
- total de placas distintas;
- quantidade de pares intra-zona;
- quantidade de pares inter-zona;
- percentual inter-zona;
- média de eventos por sessão;
- média de duração das sessões;
- distribuição por período do dia;
- ranking dos principais fluxos inter-zona.

Resultado da comparação dos cenários

Cenário A — Todos os pares

- **Total de pares:** 15.574.169
- **Total de placas:** 1.440.237
- **Pares intra-zona:** 13.708.632
- **Pares inter-zona:** 1.865.537
- **Percentual inter-zona:** 11,98%
- **Média de eventos por sessão:** 1,35
- **Média de duração:** 18,14 minutos

Esse cenário representa a visão mais abrangente da base, porém ainda é fortemente influenciado por sessões com apenas um evento, o que reforça a diagonal intra-zona.

Cenário B — Sessões com 2 ou mais eventos

- **Total de pares:** 3.836.738
- **Total de placas:** 511.815
- **Pares intra-zona:** 1.971.201
- **Pares inter-zona:** 1.865.537
- **Percentual inter-zona:** 48,62%
- **Média de eventos por sessão:** 2,43
- **Média de duração:** 73,63 minutos

Esse cenário remove as sessões triviais de um único evento e altera fortemente a estrutura da matriz O-D, aumentando significativamente a participação relativa dos fluxos inter-zona.

Cenário C — Apenas inter-zona

- **Total de pares:** 1.865.537
- **Total de placas:** 357.434
- **Pares intra-zona:** 0
- **Pares inter-zona:** 1.865.537

- **Percentual inter-zona:** 100,00%
- **Média de eventos por sessão:** 2,51
- **Média de duração:** 70,58 minutos

Esse cenário é o mais adequado quando o interesse é exclusivamente estudar deslocamentos entre regiões, mas perde a visão global do sistema ao excluir totalmente as permanências intra-zona.

Cenário D — Sessões com duração até 180 minutos

- **Total de pares:** 15.027.150
- **Total de placas:** 1.437.108
- **Pares intra-zona:** 13.407.485
- **Pares inter-zona:** 1.619.665
- **Percentual inter-zona:** 10,78%
- **Média de eventos por sessão:** 1,29
- **Média de duração:** 10,00 minutos

Esse cenário melhora a coerência temporal ao remover sessões muito longas, mas preserva quase toda a estrutura observada no cenário original, inclusive a forte dominância intra-zona.

Interpretação dos cenários

A comparação dos quatro cenários mostrou um resultado metodologicamente importante:

O principal fator que altera a estrutura da matriz O-D não é a duração das sessões, mas sim a presença de sessões com apenas um evento.

Isso fica evidente porque:

- o **Cenário D**, ao limitar a duração a 180 minutos, altera pouco a proporção inter-zona em relação ao cenário completo;
- o **Cenário B**, ao exigir pelo menos 2 eventos por sessão, eleva o percentual inter-zona de **11,98%** para **48,62%**.

Esse achado indica que o maior fator de dominância da diagonal não é apenas a existência de sessões longas, mas principalmente a grande quantidade de sessões triviais formadas por um único registro.

Distribuição por período do dia

A análise por período mostrou que os cenários preservam uma estrutura temporal semelhante, com predominância da tarde e da manhã.

Exemplo:

No cenário completo:

- tarde: 37,01%
- manhã: 32,94%
- noite: 24,86%
- madrugada: 5,19%

No cenário com 2 ou mais eventos:

- tarde: 40,20%
- manhã: 31,13%
- noite: 24,70%
- madrugada: 3,97%

Isso mostra que, mesmo com filtragem, a distribuição temporal geral da mobilidade observada permanece relativamente estável.

Robustez dos principais fluxos

Um dos resultados mais importantes da Fase 8 foi a estabilidade dos principais fluxos inter-zona entre os cenários.

Os fluxos líderes permaneceram praticamente os mesmos em:

- cenário completo;
- cenário com 2 ou mais eventos;
- cenário apenas inter-zona.

Os principais fluxos observados foram:

- **Zona 3 → Zona 1**

- **Zona 4 → Zona 2**
- **Zona 1 → Zona 5**
- **Zona 1 → Zona 3**
- **Zona 3 → Zona 4**

Por exemplo:

Fluxo Zona 3 → Zona 1

- cenário completo, tarde: **246.108**
- cenário 2+ eventos, tarde: **246.108**
- cenário inter-zona, tarde: **246.108**
- cenário duração até 180 min, tarde: **222.383**

Esse comportamento mostra que os principais padrões detectados não são frágeis nem dependem exclusivamente de um único recorte metodológico.

Validação da fase

Tamanho das tabelas

A validação confirmou os tamanhos esperados das saídas:

- comparativo_cenarios.csv → **4 linhas**
- comparativo_periodo.csv → **16 linhas**
- top_fluxos_por_cenario.csv → **40 linhas**
- recomendacao_cenario.csv → **4 linhas**

Consistência interna

Para todos os cenários, a checagem confirmou que:

$$total_{ pares } = pares_{ intra } + pares_{ inter }$$

Resultados:

- A_todos: 15.574.169
- B_2mais_eventos: 3.836.738
- C_apenas_interzona: 1.865.537
- D_duracao_ate_180: 15.027.150

Arquivos gráficos

A validação confirmou a geração correta dos 4 gráficos previstos:

- comparativo_pct_interzona.png
 - comparativo_por_perodo.png
 - comparativo_total_pares.png
 - top_fluxos_cenarios.png
-

Recomendação metodológica final

Com base na comparação dos cenários, o cenário mais equilibrado para interpretação analítica dos deslocamentos foi:

Cenário B — sessões com 2 ou mais eventos

Justificativa

Esse cenário:

- reduz a influência de sessões triviais;
- preserva um volume relevante de observações;
- mantém os principais fluxos estruturais identificados;
- aumenta bastante a visibilidade dos deslocamentos inter-zona;
- melhora a coerência interpretativa da matriz O-D.

Em termos práticos, ele oferece um equilíbrio melhor entre robustez estatística e capacidade de representar deslocamentos observáveis mais consistentes.

Interpretação geral

A Fase 8 mostrou que os padrões centrais de mobilidade observados no projeto são robustos, isto é, continuam aparecendo sob diferentes critérios de filtragem.

Isso fortalece a validade dos principais achados, especialmente:

- a centralidade do fluxo **Zona 3 → Zona 1**;
- a relevância das conexões **Zona 4 → Zona 2** e **Zona 1 → Zona 5**;
- a persistência dos principais corredores inter-zona.

Ao mesmo tempo, a fase evidenciou que a presença de sessões com apenas um evento exerce forte influência sobre a diagonal intra-zona, sendo esse o principal fator metodológico a ser considerado em análises futuras.

Conclusão da fase

A Fase 8 cumpriu com sucesso o objetivo de avaliar a sensibilidade metodológica do pipeline e fornecer uma leitura mais robusta sobre os resultados.

Ao final da etapa, o projeto passou a contar com:

- comparação estruturada entre cenários analíticos;
- evidências de robustez dos principais fluxos;
- identificação do impacto das sessões triviais;
- recomendação metodológica para interpretação dos resultados.

Essa fase fortalece significativamente a qualidade analítica do projeto, pois vai além da descrição dos fluxos e incorpora avaliação crítica das escolhas metodológicas adotadas.

Entrega da Fase 8

A entrega desta fase consiste em:

- comparação entre cenários metodológicos;
- tabelas consolidadas de robustez;
- ranking de fluxos por cenário;
- recomendação metodológica final;
- gráficos comparativos;
- validação da consistência das saídas.

Fase 9 — Dashboard Interativo e Relatório Final

Objetivo

A Fase 9 teve como objetivo transformar os resultados analíticos produzidos nas etapas anteriores em um produto final de consulta, interpretação e apresentação.

Até a Fase 8, o projeto já contava com:

- pipeline de processamento dos dados;
- definição de sessões origem-destino;
- matrizes O-D;
- modelo probabilístico;
- cadeia de Markov;
- visualizações estáticas;
- avaliação de robustez metodológica.

A Fase 9 foi criada para consolidar tudo isso em duas entregas principais:

1. **dashboard interativo**, permitindo navegação pelos resultados;
2. **relatório final**, resumindo objetivos, metodologia, achados e aplicações.

Essa fase representa o fechamento do projeto em termos de **produto analítico utilizável**, indo além da documentação técnica das fases.

Descrição da etapa

A Fase 9 utilizou como entrada os principais artefatos produzidos nas fases 5 a 8, especialmente:

- resumo executivo por período;
- rankings de fluxos inter-zona;
- rankings de transições Markov;
- destinos alternativos;
- comparação de cenários metodológicos;
- recomendação de cenário;
- matrizes O-D absolutas e probabilísticas;
- modelo probabilístico O-D;

- matriz Markov probabilística.

A partir desses dados, foram desenvolvidos:

- um script de preparação das bases do dashboard;
- um arquivo consolidado de KPIs gerais;
- um documento de apoio com a descrição das bases utilizadas;
- uma aplicação interativa em Streamlit;
- um relatório final em Markdown;
- instruções de execução da fase.

Estrutura da Fase 9

A organização adotada para a fase foi:

Text

Fase 9

```
└─ 00 ... dashboard e relatorio
    ├── input
    ├── processed
    │   ├── kpis_gerais.csv
    │   └── bases_dashboard.md
    ├── app
    │   └── dashboard.py
    ├── relatorio
    │   └── relatorio_final.md
    ├── rodar.md
    └── src
        └── preparar_base_dashboard.py
```

Produtos gerados

Arquivos processados

Foram produzidos os seguintes arquivos auxiliares para o dashboard:

- **kpis_gerais.csv**
- **bases_dashboard.md**

Aplicação interativa

Foi criado o arquivo:

- **app/dashboard.py**

Esse arquivo implementa o dashboard em Streamlit.

Relatório final

Foi criado o arquivo:

- **relatorio/relatorio_final.md**

Arquivo de execução

Também foi criado:

- **rodar.md**

com instruções para execução da fase.

Preparação das bases do dashboard

Antes da execução do dashboard, foi desenvolvido um script de preparação de dados:

- **src/preparar_base_dashboard.py**

Esse script teve como função:

- verificar a existência dos arquivos de entrada;
 - consolidar indicadores gerais;
 - gerar o arquivo de KPIs do dashboard;
 - documentar as bases utilizadas pela aplicação.
-

KPIs consolidados

A execução da preparação gerou os seguintes indicadores gerais:

- **Total de fluxos resumidos: 15.574.169**

- **Total de fluxos intra-zona:** 13.708.632
- **Total de fluxos inter-zona:** 1.865.537
- **Total de períodos analisados:** 4
- **Total de fluxos O-D agregados:** 100
- **Total de transições Markov agregadas:** 100
- **Cenário metodológico recomendado:** B_2mais_eventos

Esses indicadores foram salvos em `kpis_gerais.csv` e passaram a alimentar a aba inicial do dashboard.

Interpretação dos KPIs

Os indicadores consolidados confirmam a consistência global do pipeline:

- os totais de fluxos coincidem com os resultados das fases anteriores;
- a decomposição entre intra-zona e inter-zona foi preservada;
- os 4 períodos do dia estão representados;
- a recomendação metodológica da Fase 8 foi incorporada ao produto final.

Os valores **100** para fluxos O-D agregados e transições Markov agregadas correspondem ao número de combinações/células agregadas nas matrizes, e não ao volume bruto total de eventos ou transições.

Dashboard interativo

Objetivo do dashboard

O dashboard foi desenvolvido para permitir a exploração interativa dos resultados do projeto, facilitando a leitura por diferentes públicos:

- público técnico;
- avaliadores acadêmicos;
- usuários leigos;
- tomadores de decisão.

Tecnologia adotada

Foi utilizada a biblioteca **Streamlit**, por ser:

- simples de implementar;
 - adequada para dashboards locais;
 - compatível com pandas, DuckDB e Plotly;
 - apropriada para apresentação acadêmica e prototipagem analítica.
-

Estrutura do dashboard

A aplicação foi organizada em múltiplas páginas acessadas por menu lateral.

1. Apresentação do Projeto

Essa página foi criada para comunicar os resultados em linguagem mais acessível, com foco em público não técnico.

Ela apresenta:

- explicação do que foi feito;
- principais entregas;
- critérios qualitativos de avaliação;
- principais achados;
- impacto prático;
- explicação do uso de IA;
- limitações.

Essa aba é especialmente importante porque conecta a análise técnica aos objetivos do projeto e facilita a apresentação para banca, professor ou público leigo.

2. Visão Geral

Apresenta:

- KPIs principais;
- tabela com resumo executivo por período;
- gráfico comparando fluxos intra-zona e inter-zona.

Essa página oferece uma visão resumida do comportamento global da mobilidade observada.

3. Matriz O-D

Permite selecionar:

- período do dia;
- tipo de matriz: absoluta ou probabilística.

Exibe:

- tabela da matriz;
- heatmap interativo.

Essa página permite observar diretamente a distribuição dos deslocamentos entre zonas.

4. Fluxos Inter-Zona

Apresenta:

- tabela com os principais fluxos inter-zona;
- filtro por período;
- gráfico de barras horizontal com os fluxos mais importantes.

Essa aba destaca os principais corredores de mobilidade entre regiões.

5. Modelo Probabilístico

Permite selecionar:

- período;
- zona de origem.

Exibe:

- tabela ordenada dos destinos;
- gráfico da distribuição de probabilidades;
- tabela de destinos alternativos.

Essa aba materializa a lógica de:

$$P(\text{destino} \mid \text{origem}, \text{período})$$

6. Markov

Apresenta:

- matriz de transição probabilística por período;
- heatmap interativo;
- tabela das principais transições inter-zona.

Essa página traduz a mobilidade em termos sequenciais, com foco nas próximas zonas observadas.

7. Robustez

Apresenta:

- comparação entre cenários metodológicos;
- gráfico de total de pares por cenário;
- gráfico de percentual inter-zona por cenário;
- distribuição por período;
- recomendação final.

Essa aba incorpora os resultados da Fase 8 diretamente ao produto final.

Aba “Apresentação do Projeto”

Um dos aprimoramentos importantes da Fase 9 foi a criação de uma aba introdutória voltada à explicação do projeto para pessoas leigas ou não especializadas.

Essa aba cumpre funções essenciais:

- contextualizar os dados;
- explicar o que foi produzido;
- resumir os principais achados;
- evidenciar o impacto prático;
- justificar o uso de IA;
- tornar o dashboard mais apresentável como produto final.

Essa decisão foi importante porque um dashboard puramente técnico poderia dificultar a compreensão do projeto por avaliadores que não acompanharam todas as fases detalhadamente.

Uso de Inteligência Artificial no projeto

Embora o projeto não tenha utilizado redes neurais ou aprendizado supervisionado clássico, ele empregou uma estratégia de IA compatível com a natureza do problema.

Estratégia adotada

A abordagem foi híbrida, combinando:

1. Pré-processamento temporal

- ordenação por veículo e tempo;
- construção de sequências de leitura.

2. Clusterização espacial

- agrupamento de sensores em zonas urbanas;
- redução da granularidade e aumento da interpretabilidade.

3. Inferência de trajetórias

- origem = primeira aparição observada;
- destino = última aparição observada;
- uso de frequência de transições para inferir trajetos.

4. Modelagem probabilística

- estimação de probabilidades condicionais de destino;
- tratamento de incerteza em dados incompletos.

5. Cadeias de Markov

- modelagem da próxima zona a partir da zona atual;
- representação sequencial do comportamento de mobilidade.

Justificativa

Essa abordagem foi escolhida porque:

- o problema não possui rótulos supervisionados;

- os dados são incompletos;
- a incerteza precisa ser tratada explicitamente;
- o projeto exige interpretabilidade.

Portanto, o uso de IA no projeto se materializa em técnicas clássicas de análise não supervisionada e modelagem probabilística, adequadas ao contexto real dos dados.

Aplicações práticas

A Fase 9 evidencia que o projeto pode apoiar usos práticos como:

- identificação de corredores de tráfego mais utilizados;
- apoio a decisões de transporte público;
- melhoria do planejamento urbano;
- visualização de padrões temporais de mobilidade;
- construção de cenários para gêmeos digitais;
- suporte a estudos futuros de previsão e simulação.

Relatório final

Além do dashboard, a Fase 9 também incluiu a criação de um relatório final em Markdown.

Esse documento consolida:

- objetivo do projeto;
- etapas executadas;
- principais resultados;
- principal conclusão metodológica;
- produto final;
- sugestões de trabalhos futuros.

O relatório serve como material complementar de apoio, permitindo uma visão mais estruturada do projeto fora do ambiente interativo.

Validação prática da fase

A preparação das bases foi executada com sucesso e gerou corretamente:

- processed/kpis_gerais.csv
- processed/bases_dashboard.md

Os KPIs gerados ficaram consistentes com os resultados das fases anteriores, o que confirma que a integração dos dados na Fase 9 foi realizada corretamente.

Além disso, a estrutura do dashboard foi preparada para leitura direta das bases em CSV e Parquet, com cache de leitura para melhorar a performance local.

Interpretação da Fase 9

A Fase 9 representa a passagem do projeto de um pipeline analítico para um produto final utilizável.

Ela amplia o valor do trabalho em três dimensões:

1. Técnica

Integra diferentes camadas analíticas em uma única interface.

2. Comunicacional

Torna os resultados compreensíveis para públicos não técnicos.

3. Aplicada

Demonstra como os dados podem ser usados em apoio a planejamento urbano e mobilidade.

Conclusão da fase

A Fase 9 cumpriu com sucesso o objetivo de consolidar o projeto em um formato final de apresentação e exploração interativa.

Ao final da etapa, o projeto passou a contar com:

- dashboard interativo em Streamlit;
- KPIs consolidados;
- relatório final em Markdown;
- aba explicativa para público leigo;
- integração dos resultados das fases anteriores;

- justificativa clara do uso de IA no contexto do problema.

Essa fase funciona como a camada final de entrega do projeto, tornando os resultados não apenas corretos do ponto de vista analítico, mas também acessíveis, comunicáveis e aplicáveis.

Entrega da Fase 9

A entrega desta fase consiste em:

- script de preparação das bases do dashboard;
- arquivo consolidado de KPIs gerais;
- documentação das bases do dashboard;
- aplicação interativa em Streamlit;
- relatório final em Markdown;
- instruções de execução da fase;
- apresentação acessível dos resultados;
- explicação do uso de IA na solução.

Conclusão

O projeto demonstrou a viabilidade de transformar dados brutos de sensores em inferências de mobilidade robustas, mesmo com cobertura espacial limitada. A combinação de técnicas de limpeza em larga escala (DuckDB), clusterização espacial (KMeans) e modelagem probabilística (Cadeias de Markov) permitiu identificar padrões de deslocamento estáveis e de fácil interpretação. O principal produto, um dashboard interativo, oferece uma ferramenta de consulta para tomadores de decisão e planejadores urbanos. Este trabalho evidencia que é possível extrair valor analítico significativo de dados de tráfego incompletos, apoiando desde a identificação de corredores críticos até estudos futuros de simulação de cenários.